CONFIABILIDADE DE LLMs

Sycophancy em Grandes Modelos de Linguagem: avaliação de capitulação, correção seletiva e risco em múltiplos domínios

Natasha Almeida Trindade — RA: 22.123.098-0
Douglas Honda — RA: 22.123.006-3
Marcus Vinicius Zanelato — RA: 22.123.084-9

Ciência da Computação · TCC 1 — Apresentação Parcial

Orientador: Fagner Pimentel

Sycophancy em LLMs: capitulação, correção seletiva e risco em múltiplos domínios

Introdução

Do contexto amplo ao problema investigado

1 Contexto geral

LLMs já mediam decisões e geração de conteúdo. O alinhamento por preferências busca utilidade e cooperação, mas pode criar tensão entre agradar o usuário e preservar a veracidade.

2 Contexto específico

Sycophancy é a tendência de acomodar a crença ou sugestão do usuário mesmo quando ela é incorreta. Em diálogos multi-turno, pressão sustentada pode induzir mudança de posição.

3 Motivação

Em domínios de diferentes níveis de criticidade, a mesma tendência de concordar pode variar de um erro inofensivo a uma orientação potencialmente prejudicial. A fluência do LLM pode mascarar essa falha.

4 Justificativa

Um protocolo padronizado permite medir não só quando o modelo capitula, mas também se sua resistência aumenta conforme cresce o potencial de dano.

Mecanismo + consequência que o trabalho quer medir



Pergunta de pesquisa: quando, como e com que frequência um LLM troca a correção pela concordância e quão grave pode ser essa falha?

Base conceitual: Sharma et al. (2024); Hong et al. (2025).

Objetivos

Objetivo geral : Quantificar e comparar o comportamento de sycophancy em diferentes LLMs sob pressão do usuário, avaliando capitulação, correção seletiva e gravidade potencial das falhas em cenários de diferentes níveis de criticidade.

01 Definir

um protocolo reproduzível de prompts pareados (premissas corretas × incorretas) e níveis de pressão em diálogos com múltiplos turnos.

02 Executar

os testes em diferentes LLMs sob configurações padronizadas, registrando respostas e condições experimentais para permitir comparação.

03 Mensurar

taxa de capitulação, turno da primeira mudança, frequência de mudanças e correção seletiva diante de sugestões válidas e inválidas.

04 Comparar

modelos, domínios e níveis de criticidade, relacionando a frequência de capitulação à gravidade potencial da resposta incorreta e identificando cenários de maior risco.

Saídas mensuráveis taxa de capitulação • turno da 1ª mudança • correção seletiva • persistência • gravidade potencial • comparação por criticidade

Trabalhos relacionados

Evolução: descoberta do fenômeno → causas → diálogo multi-turno → seletividade à correção

Perez et al. (2023) · ACL Findings

DESCOBERTA

Contribuição. Avaliações escritas por LMs mostraram que modelos maiores podem repetir a resposta preferida do usuário; o trabalho também observou casos de piora com mais RLHF.
Lacuna p/ nosso recorte. Estudo amplo; não é um benchmark dedicado a sycophancy multi-turno por domínio.

Sharma et al. (2024) · ICLR

RLHF / PREFERÊNCIAS

Contribuição. Cinco assistentes, em quatro tarefas, exibiram sycophancy; julgamentos humanos e modelos de preferência às vezes favoreceram respostas sicofânticas em vez das corretas.
Lacuna p/ nosso recorte. Foca prevalência/causas, não a severidade entre domínios.

Hong et al. (2025) · EMNLP Findings

MULTI-TURNO

Contribuição. O SYCON Bench avalia 17 LLMs em diálogo multi-turno com Turn of Flip e Number of Flip; uma estratégia em 3ª pessoa reduziu sycophancy em até 63,8% no debate.
Lacuna p/ nosso recorte. Não é centrado em consequências entre domínios.

Sinha (2026) · ACL Findings

SELETIVIDADE

Contribuição. O SycoBench-600 usa 600 questões em inglês, três tipos de pressão e sete assistentes para separar "aceitar correção" de "ceder à sugestão errada".
Lacuna p/ nosso recorte. Múltipla escolha em inglês; menor dinâmica de conversa livre.